UNIVERSIDAD NACIONAL
DE ROSARIO
FACULTAD DE CIENCIAS
ECONÓMICAS Y ESTADÍSTICA



UNR

Trabajo Práctico de Series de Tiempo

Análisis de muertes por Accidentes Cerebrovasculares (ACV) en Estados Unidos

Alumna: Cañizares, María Inés

Licenciatura en Estadística

Año 2026

Introducción

El Accidente Cerebrovascular (ACV), conocido popularmente como "derrame cerebral" o "ataque cerebral", es una afección médica que ocurre cuando se interrumpe el flujo de sangre hacia una parte del cerebro, ya sea porque un vaso sanguíneo se obstruye o porque se rompe. Esta interrupción hace que las células cerebrales de la zona afectada dejen de recibir oxígeno y nutrientes, lo que puede provocar daños permanentes en cuestión de minutos.

El ACV es uno de los principales problemas de salud pública a nivel mundial. Es una de las principales causas de muerte y, entre quienes sobreviven, una de las principales causas de discapacidad a largo plazo, ya que puede dejar secuelas como parálisis, dificultades para hablar o problemas cognitivos. Además, es una enfermedad estrechamente relacionada con factores que varían a lo largo del año, como la presión arterial y la temperatura ambiente, lo que la convierte en un fenómeno interesante para analizar desde una perspectiva temporal: ¿la cantidad de muertes por esta causa se mantiene estable a lo largo de los años, o cambia? ¿Existen ciertas épocas del año donde el riesgo es mayor?

Entender cómo evoluciona la mortalidad por ACV a través del tiempo es relevante no solo desde el punto de vista médico, sino también para la planificación de recursos sanitarios: si se pudiera anticipar en qué meses o períodos aumenta el riesgo, los sistemas de salud podrían prepararse mejor (por ejemplo, reforzando personal o insumos en los meses de mayor demanda).

Por este motivo, en este trabajo se analiza la evolución mensual de la cantidad de muertes por ACV en Estados Unidos entre los años 1999 y 2019, utilizando datos públicos provenientes de CDC WONDER, una base de datos oficial del gobierno estadounidense que recopila estadísticas vitales del país. El objetivo es describir el comportamiento de esta serie a lo largo del tiempo e identificar si existen patrones recurrentes, como tendencias de largo plazo o variaciones estacionales asociadas a las distintas épocas del año.

Análisis descriptivo de la serie temporal

Se presenta la serie temporal de las muertes por ACV mensual en Estados Unidos durante el período 1999–2018. El gráfico permite visualizar de manera global cómo se ha comportado la variable en el tiempo.

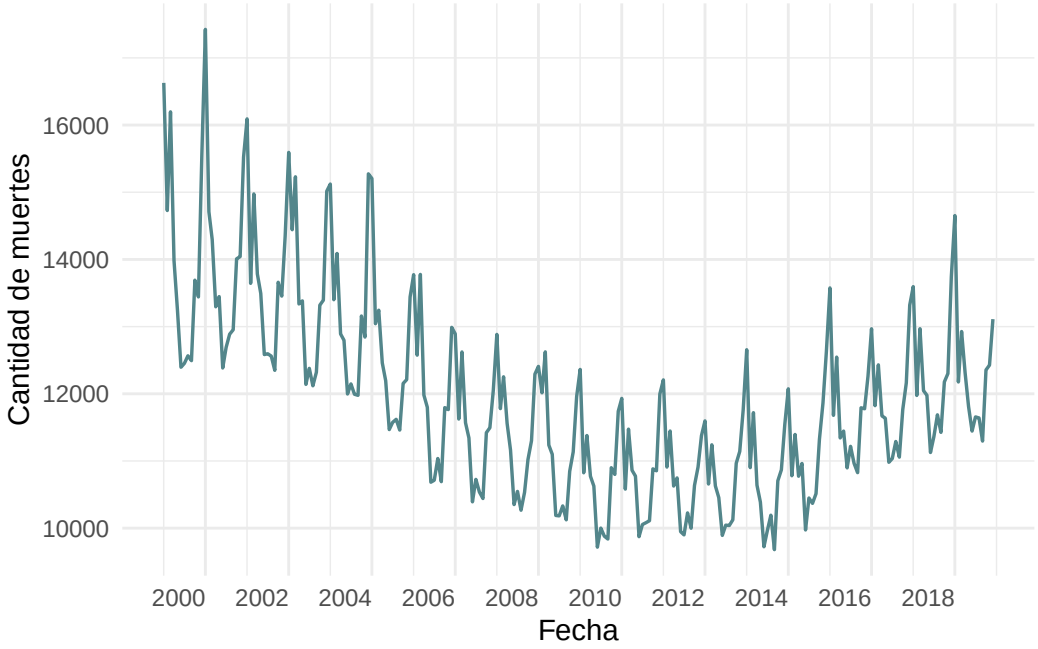


Figura 1: Evolución de las muertes mensuales por ACV en Estados Unidos (1999–2018)

El análisis de la serie muestra que se trata de una variable con periodicidad mensual, con 12 observaciones por año. En cuanto a la tendencia, no se observa un comportamiento uniforme a lo largo de todo el período: entre 1999 y 2010 se registra un descenso sostenido en la cantidad de muertes, mientras que a partir de 2011 la serie comienza a mostrar una recuperación progresiva, con un crecimiento que se mantiene hasta el final del período en 2018. Este patrón refleja un cambio de dirección en la tendencia, describiendo una forma de "U" a lo largo de los veinte años analizados, lo que indica que la serie no es estacionaria en media.

Respecto a la estacionalidad, se observa un comportamiento recurrente año tras año, caracterizado por valores máximos en los meses de invierno (diciembre, enero y febrero) y valores mínimos en los meses de verano (junio a septiembre). No se detectaron valores faltantes en el período estudiado.

Con el fin de profundizar en el análisis de la tendencia y la variabilidad de la serie, se construyó un gráfico de boxplots anuales (Figura 2), que permite visualizar la distribución de los datos mes a mes agrupados por año.

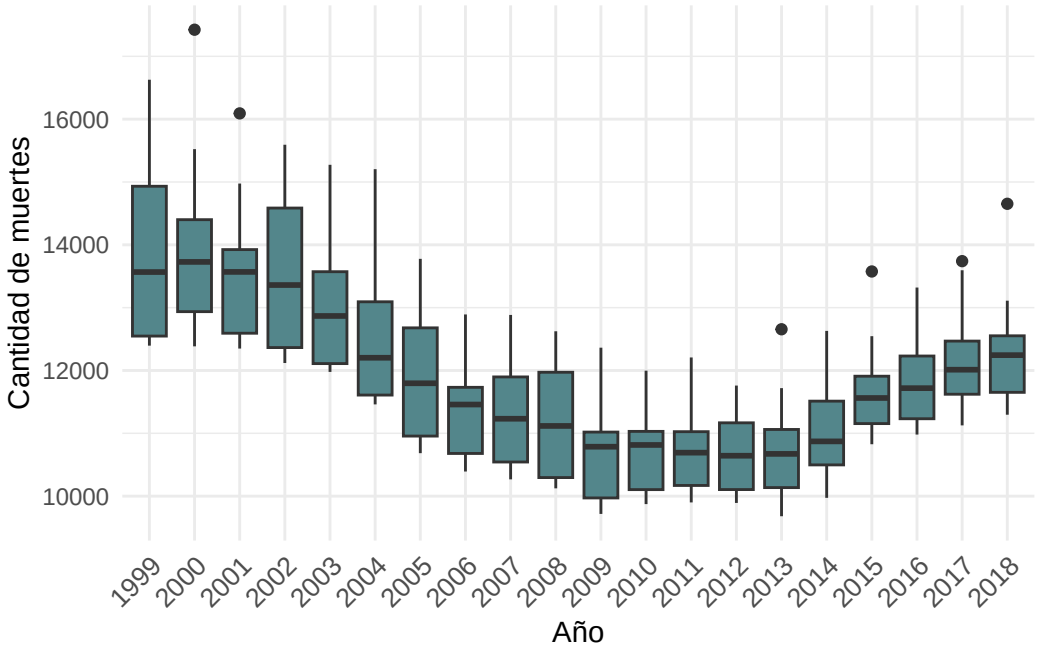


Figura 2: Distribución anual de las muertes por ACV en Estados Unidos (1999–2018)

Las medianas anuales confirman el mismo patrón en forma de "U" descrito anteriormente: descienden desde 1999 hasta aproximadamente 2010-2011, para luego aumentar de manera sostenida hasta 2018.

En cuanto a la dispersión, se observa que la amplitud de las cajas (rango intercuartílico) no se mantiene constante a lo largo del período: es mayor en los primeros años de la serie (1999-2003) y en los últimos (2016-2018), mientras que se reduce notablemente durante los años centrales (2008-2013). Esta variación en la dispersión acompaña al nivel general de la serie, lo que sugiere que la variancia no es estable en el tiempo, es decir, se evidencia heterocedasticidad.

Asimismo, se identifican algunos valores atípicos (outliers) en determinados años, correspondientes principalmente a meses de invierno con picos de mortalidad inusualmente altos respecto al resto de las observaciones de ese mismo año.

Para analizar con mayor detalle el comportamiento estacional de la serie, se elaboró un gráfico estacional (Figura 3), en el cual se superponen las observaciones de cada año, ordenadas por mes, con el fin de comparar la forma del patrón estacional entre los distintos años.

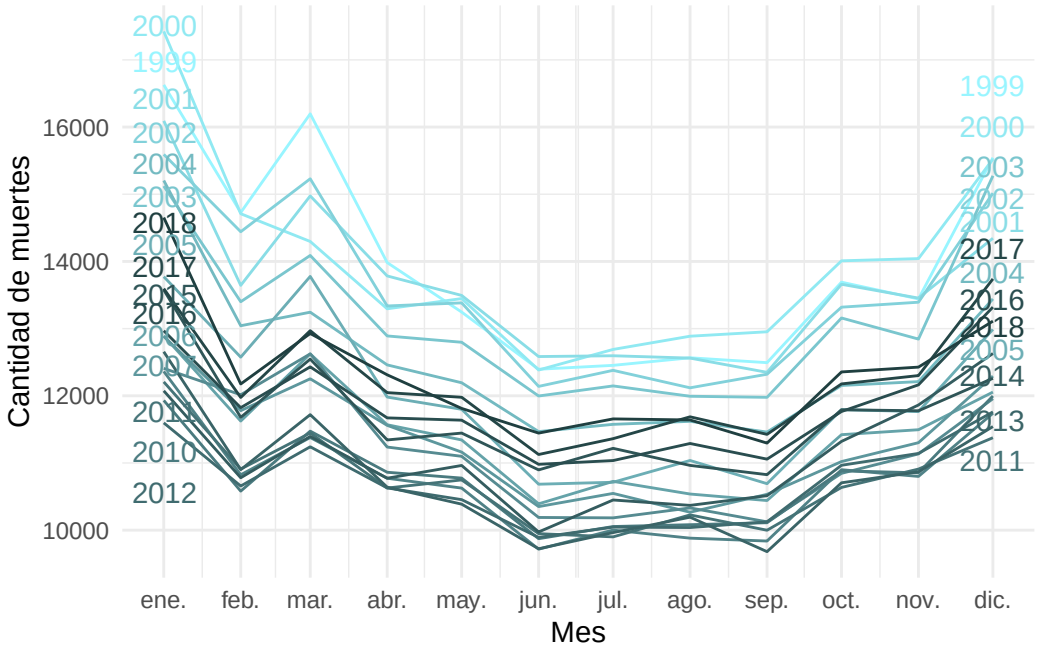


Figura 3: Gráfico estacional de las muertes por ACV en Estados Unidos (1999–2018)

Se observa que la forma del ciclo estacional se mantiene notablemente estable a lo largo de todo el período: en todos los años, los valores más altos se concentran en los meses de diciembre y enero, mientras que los valores más bajos se registran entre junio y septiembre. Lo que varía entre los distintos años no es la forma de la curva, sino su nivel general, lo cual es consistente con la tendencia en forma de "U" identificada previamente: las curvas correspondientes a los primeros años (1999-2003) y a los últimos (2016-2018) se ubican en niveles más altos, mientras que las curvas de los años centrales (2008-2013) se ubican en niveles más bajos. En síntesis, el gráfico estacional confirma la presencia de un patrón estacional anual marcado y persistente en el tiempo, lo que refuerza la evidencia de no estacionariedad de la serie observada en los análisis anteriores.

Con el objetivo de aislar el efecto de cada mes en particular a lo largo de toda la serie, se construyó un gráfico de subseries estacionales, donde cada panel representa un mes del año y la línea horizontal indica el promedio histórico de ese mes para todo el período analizado.

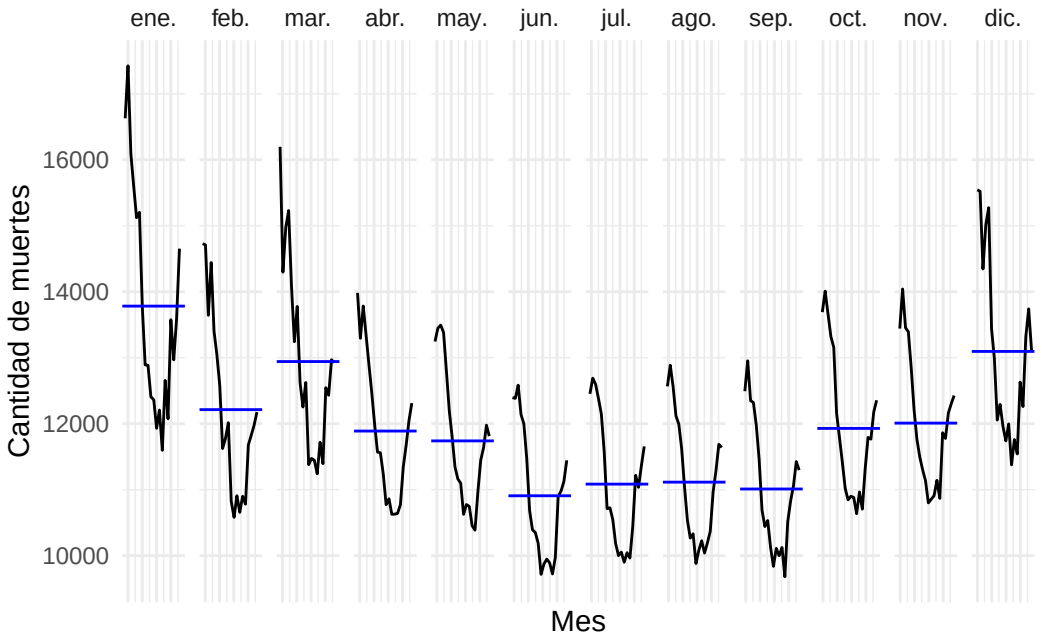


Figura 4: Gráfico de subseries estacionales de las muertes por ACV en Estados Unidos (1999–2018)

La Figura 4 confirma lo observado en las figuras anteriores: los meses de diciembre y enero presentan los promedios más altos de mortalidad, mientras que los meses de junio a septiembre muestran los promedios más bajos, evidenciando nuevamente el patrón estacional de tipo invierno-verano. Asimismo, dentro de cada panel se puede apreciar que la evolución temporal del mes correspondiente también sigue la forma de "U" identificada en la tendencia general de la serie, lo que indica que este comportamiento no solo se da en el nivel agregado, sino que se repite de manera consistente mes a mes. En conjunto, este gráfico refuerza la evidencia de un componente estacional fuerte y estable en el tiempo, que convive con una tendencia no constante a lo largo del período estudiado.

Finalmente, para contar con una confirmación estadística de las características observadas en los gráficos anteriores, se calculó la función de autocorrelación muestral, considerando hasta 36 rezagos.

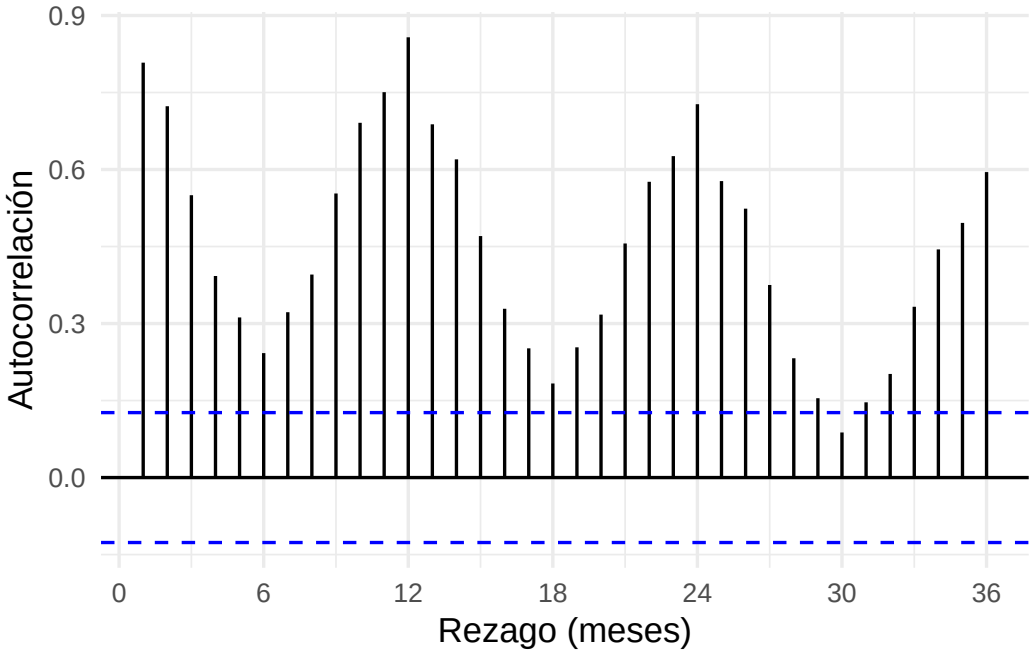


Figura 5: Función de autocorrelación de las muertes por ACV

En la Figura 5 se observa un pico de autocorrelación particularmente alto en el rezago 12, que vuelve a repetirse con menor intensidad en los rezagos 24 y 36, lo cual constituye evidencia formal de la estacionalidad anual detectada previamente de manera gráfica. Asimismo, se observa que las autocorrelaciones no decaen rápidamente hacia cero a medida que aumenta el rezago, sino que lo hacen de forma lenta y sostenida, manteniéndose por encima de la banda de significancia en la gran mayoría de los rezagos analizados. Este comportamiento es característico de series no estacionarias, ya que refleja la presencia de una dependencia de largo plazo asociada tanto a la tendencia como a la estacionalidad presentes en la serie. En síntesis, el correlograma confirma de manera formal lo observado en el análisis gráfico previo, evidenciando que la serie no es estacionaria ni en media ni en varianza.

Complementando el análisis de la función de autocorrelación, se calculó también la función de autocorrelación parcial, que permite identificar la correlación directa entre una observación y su rezago, eliminando el efecto de los rezagos intermedios.

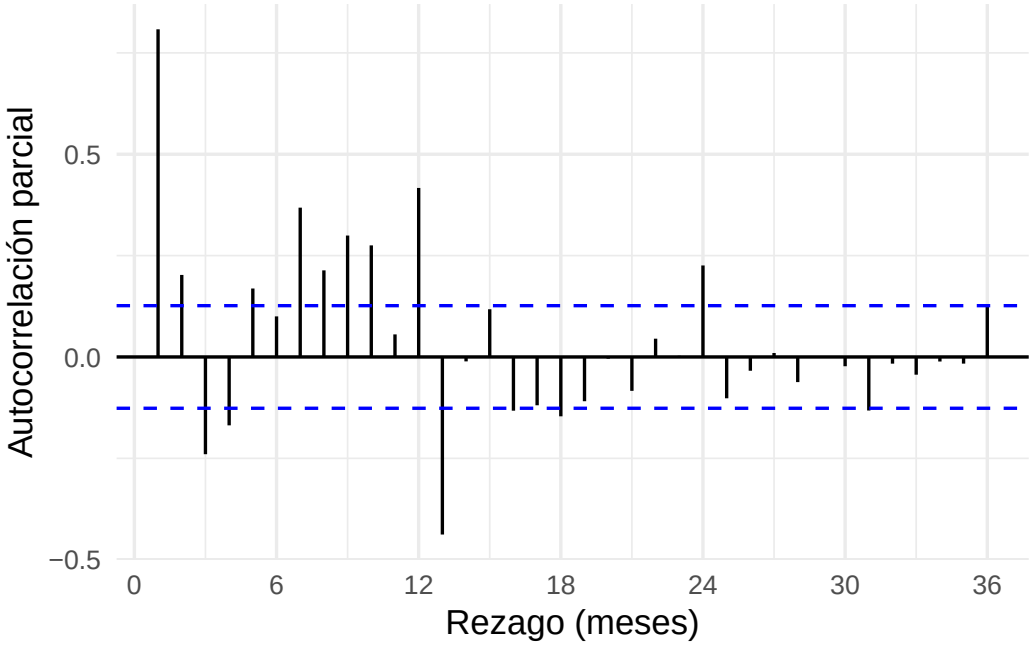


Figura 6: Función de Autocorrelación Parcial de las muertes por ACV

La Figura 6 muestra un primer coeficiente muy elevado en el rezago 1 (cercano a 0,8), seguido de varios coeficientes significativos de menor magnitud entre los rezagos 2 y 10, con signos alternantes. Se destaca además un coeficiente marcadamente negativo en el rezago 12 (cercano a -0,4), que resulta notablemente mayor en valor absoluto que el resto de los coeficientes a partir del rezago 13, los cuales se ubican mayormente dentro de la banda de significancia o apenas por fuera de ella, salvo un pico aislado cercano al rezago 24. Este comportamiento sugiere que, además de la dependencia de corto plazo reflejada en los primeros rezagos, persiste cierta estructura asociada al componente estacional de la serie, evidenciada por el coeficiente significativo en el rezago 12. En conjunto, el correlograma parcial refuerza la idea de que la serie presenta una estructura de dependencia compleja, consistente con la presencia simultánea de componentes de corto plazo y de estacionalidad, lo que confirma nuevamente que la serie no es estacionaria en su forma original.

Especificación del modelo

En primer lugar, con el objetivo de evaluar si la variabilidad cambia con el nivel de la serie, se analizó la relación entre la media anual y el desvío estándar anual. Esta relación permite observar si existe una tendencia creciente entre ambos valores: cuando las observaciones de mayor nivel también muestran una mayor dispersión, suele ser indicio de varianza no constante y, por lo tanto, puede justificar la aplicación de una transformación Box–Cox para estabilizarla.

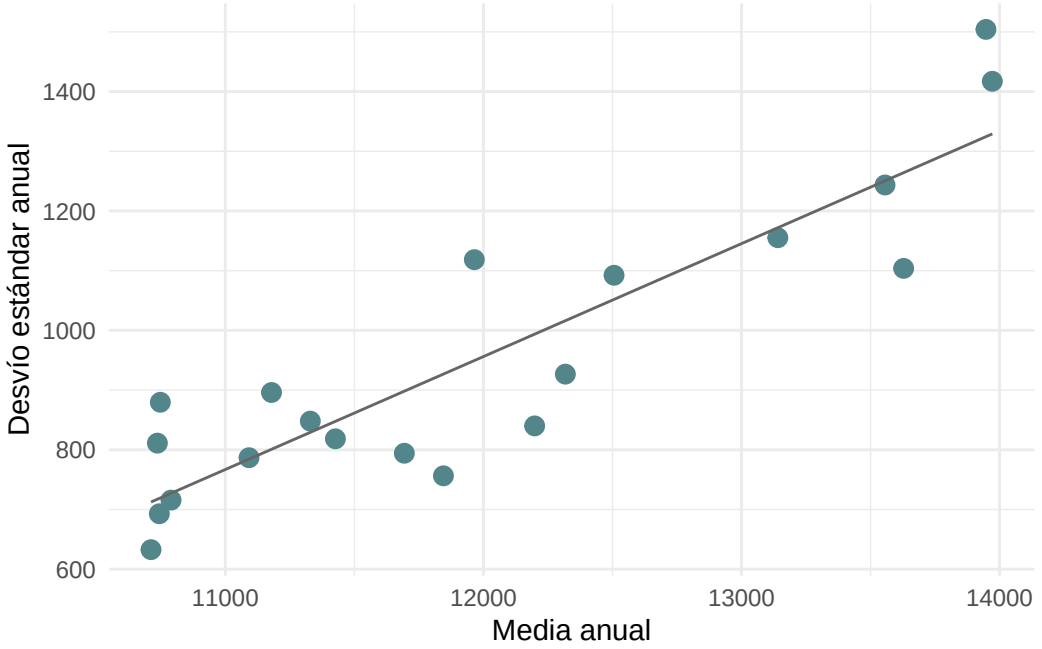


Figura 7: Relación entre media y desvío estándar anual

La Figura 7 muestra una relación creciente, lo que indica que la variancia depende del nivel de la serie.

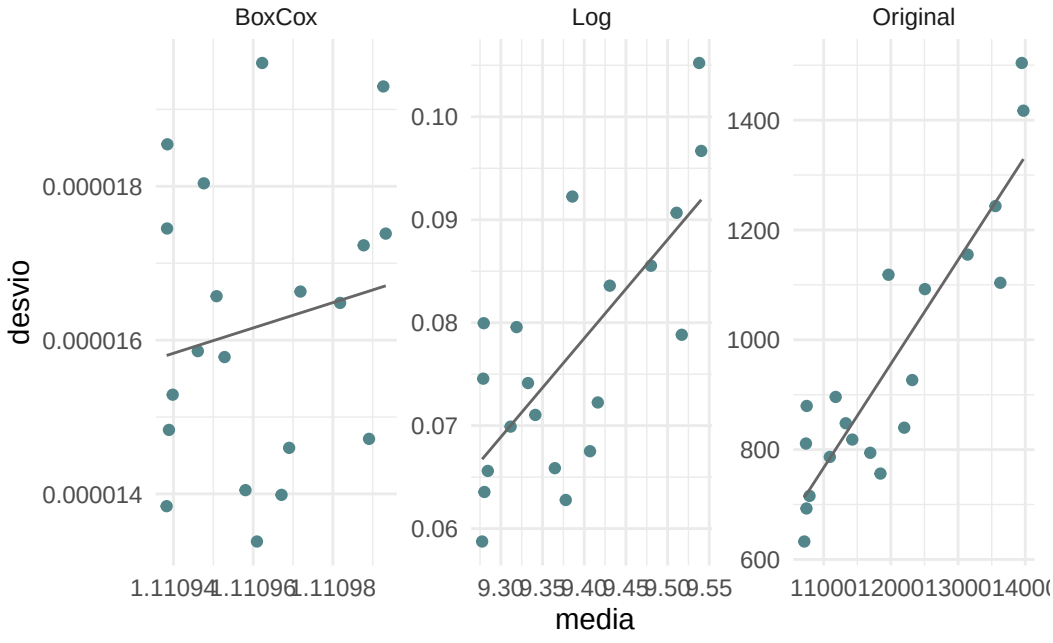


Figura 8: Transformaciones de variancia

La transformación logarítmica reduce, pero no elimina, esta dependencia. En cambio, la transformación de Box-Cox con $\lambda \approx -0{,}9$ (estimado por el método de Guerrero) deja el desvío aproximadamente constante respecto de la media, por lo que se adopta para el resto del análisis.

Una vez evaluada la necesidad de estabilizar la variancia, el siguiente paso consiste en lograr que la serie sea estacionaria en media. Para ello se emplea la diferenciación, que elimina patrones sistemáticos de la serie: la diferenciación regular, $(1-B)^d$, elimina tendencias de largo plazo, y la diferenciación estacional, $(1-B^{12})^D$, elimina las fluctuaciones que se repiten de forma regular cada año.

Para determinar los órdenes d y D se emplearon pruebas de raíz unitaria (basadas en el estadístico KPSS), complementadas con el análisis gráfico de la serie y de sus funciones de autocorrelación. Dada la marcada estacionalidad anual, se aplicó primero la diferencia estacional, siguiendo la recomendación de Hyndman y Athanasopoulos.

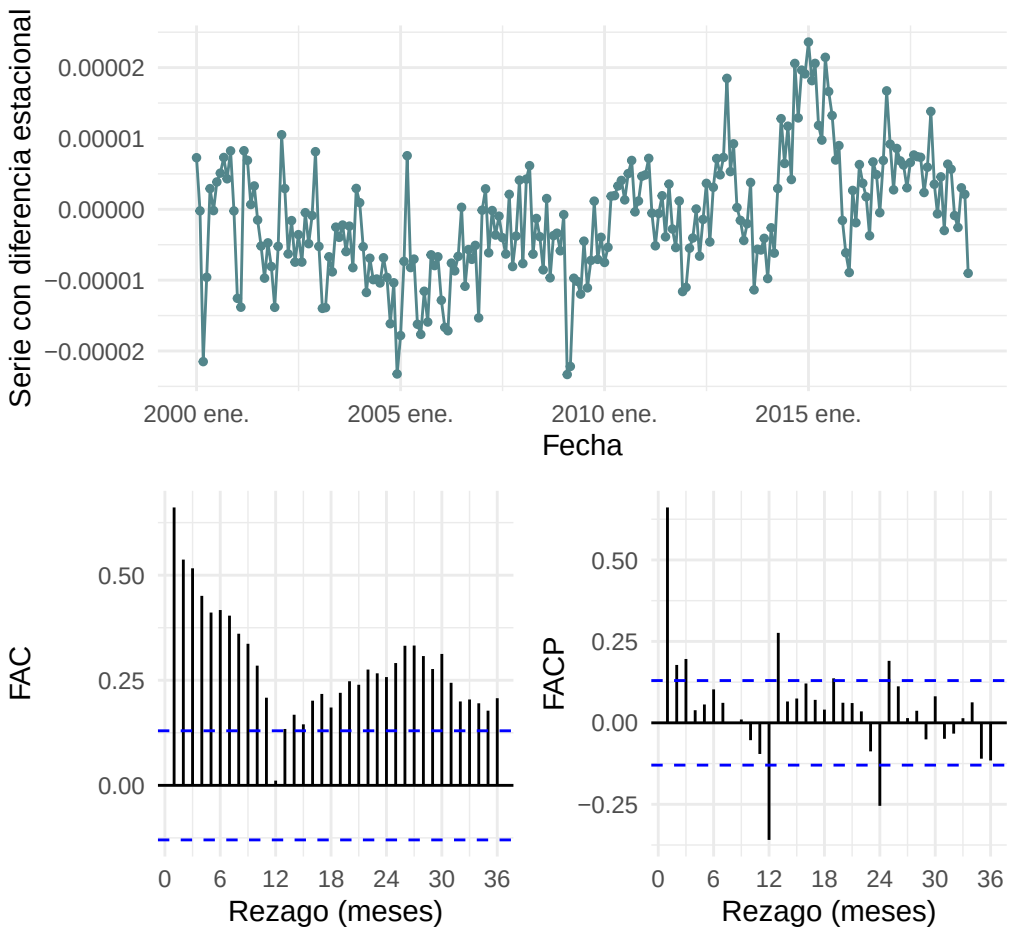


Figura 9: Serie transformada con una diferencia estacional, con su FAC y FACP

La prueba indicó que se requiere una diferencia estacional. Sin embargo, al observar la serie

con diferencia estacional (Figura 9), se ve que su nivel se desplaza a lo largo del tiempo, con un tramo de valores altos entre 2013 y 2016, y que su función de autocorrelación decae lentamente, con valores positivos y significativos en casi todos los rezagos. Esto indica que persiste una tendencia. Coincidentemente, la prueba para diferencias regulares aplicada sobre esta serie indicó una diferencia adicional.

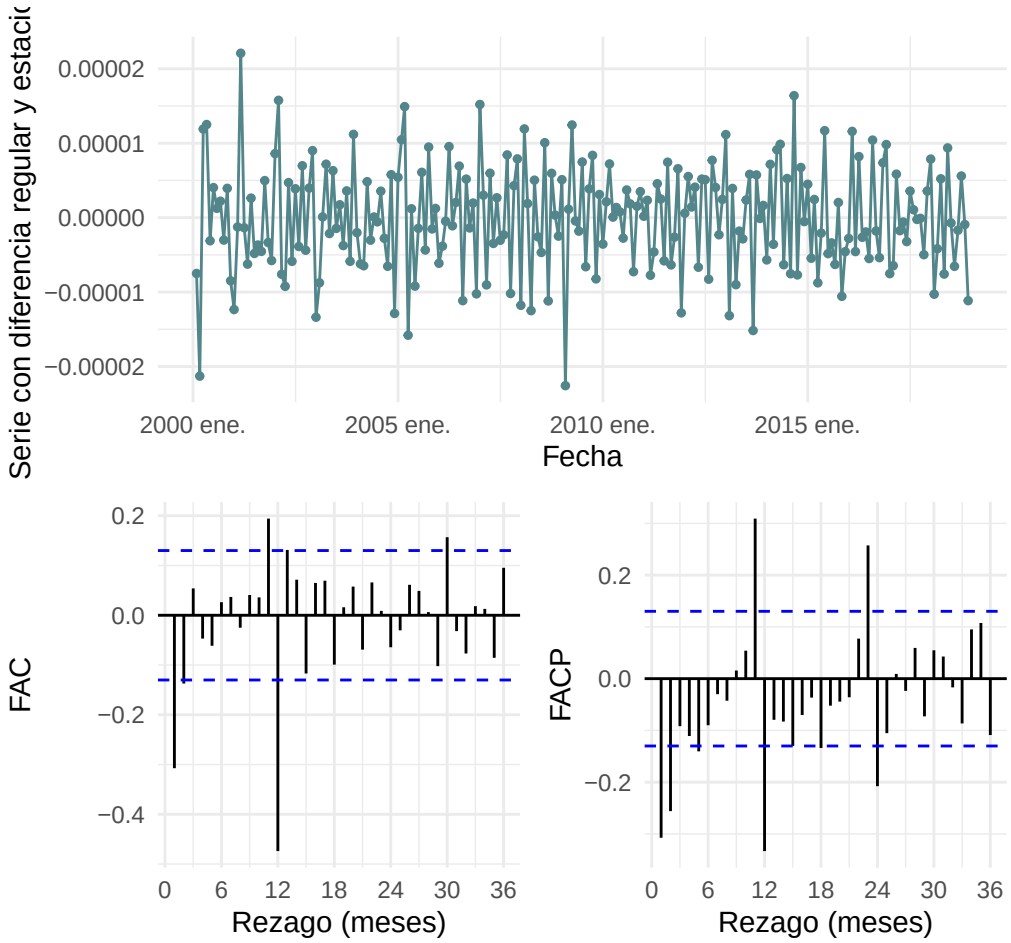


Figura 10: Serie transformada con una diferencia regular y una estacional, con su FAC y FACP

Al aplicar ambas diferencias (Figura 10), la serie oscila alrededor de cero con variabilidad aproximadamente constante y sin tendencia aparente. Además, la autocorrelación en el rezago 1 es cercana a $-0{,}3$, lejos del valor de $-0{,}5$ a partir del cual suele sospecharse sobrediferenciación. Se adopta entonces $d = 1$ y $D = 1$.

Identificación de modelos candidatos

A partir de la FAC y la FACP de la serie diferenciada (Figura 10):

- En la FAC hay un pico negativo en el rezago 1 y otro más marcado en el rezago 12, con valores pequeños alrededor de los rezagos 11 y 13. Es un patrón característico de un término de promedios móviles no estacional de orden 1 y de uno estacional de orden 1.
- En la FACP los rezagos 1 y 2 son negativos y significativos, y en la parte estacional los rezagos 12 y 24 son negativos con magnitud decreciente. Esto es consistente con la parte de promedios móviles estacional y sugiere que podría hacer falta un segundo término de promedios móviles no estacional.

Se proponen entonces tres modelos candidatos, SARIMA$(p,d,q)(P,D,Q)_{12}$: (1) $(0,1,1)(0,1,1)$, (2) $(0,1,2)(0,1,1)$ y (3) $(2,1,0)(2,1,0)$, este último como alternativa puramente autorregresiva sugerida por la FACP. Se incluye además, como referencia, el modelo seleccionado por el algoritmo automático de búsqueda.

Ajuste y diagnóstico

Los modelos se estimaron por máxima verosimilitud sobre la serie transformada. Como todos comparten la misma transformación y los mismos órdenes de diferenciación, pueden compararse mediante AICc y BIC (Tabla 1).

Tabla 1: Comparación de los modelos candidatos

Modelo	AICc	BIC
ARIMA(0,1,2)(0,1,1)[12]	-4874.32	-4860.80
ARIMA(0,1,1)(0,1,1)[12]	-4870.79	-4860.62
Automático: ARIMA(0,1,1)(2,1,2)[12]	-4868.60	-4848.43
ARIMA(2,1,0)(2,1,0)[12]	-4853.04	-4836.19

El modelo SARIMA$(0,1,2)(0,1,1)_{12}$ presenta los menores valores de AICc y BIC. El modelo automático, que resultó ser un SARIMA$(0,1,1)(2,1,2)_{12}$, es más complejo y casi todos sus coeficientes estacionales no son significativos, lo que sugiere sobreparametrización. El modelo autorregresivo es el de peor ajuste.

Se realiza el ajuste para el modelo ARIMA$(0,1,2)(0,1,1)_{12}$ sobre la serie transformada Z_t:

$$(1-B)(1-B^{12})Z_t = (1-\theta_1 B-\theta_2 B^2)(1-\Theta_1 B^{12})\,a_t,$$

donde Z_t es la serie transformada mediante Box-Cox con $\hat{\lambda} = -0{,}90$ y a_t es ruido blanco. De esta forma, el modelo estimado queda:

$$(1-B)(1-B^{12})Z_t = (1-0{,}4580B-0{,}1598B^2)(1-0{,}7814B^{12})\,a_t.$$

Tabla 2: Coeficientes estimados del modelo SARIMA(0,1,2)(0,1,1)[12]

Parámetro	Estimación	Error estándar	IC 95 % inferior	IC 95 % superior
ma1	-0.4580	0.0686	-0.5925	-0.3235
ma2	-0.1598	0.0663	-0.2898	-0.0298
sma1	-0.7814	0.0561	-0.8914	-0.6714

Los tres coeficientes resultan significativos, ya que sus intervalos de confianza del 95 % no contienen al cero (Tabla Tabla 2). Además, el coeficiente estacional ($-0{,}78$) se encuentra alejado de -1, por lo que el modelo es invertible.

Para el diagnóstico de los residuos se excluyeron las primeras 13 observaciones, cuyos residuos dependen de las condiciones iniciales de la diferenciación.

Se procede entonces con el análisis de los residuos para este primer modelo, iniciando con el Test de Portmanteau para verificar si la hipótesis de que los mismos son ruido blanco se cumple:

Tabla 3: Test de Portmanteau de los residuos del modelo SARIMA(0,1,2)(0,1,1)[12]

Rezago	Estadística	gl	p-value
6	3.654	3	0.301
12	15.131	9	0.087
18	17.551	15	0.287
24	24.919	21	0.251

Los valores del test muestran que ningún p-value es significativo para ninguno de los rezagos evaluados (todos mayores a 0.05), por lo que los residuos se comportan como ruido blanco y no presentan autocorrelación significativa.

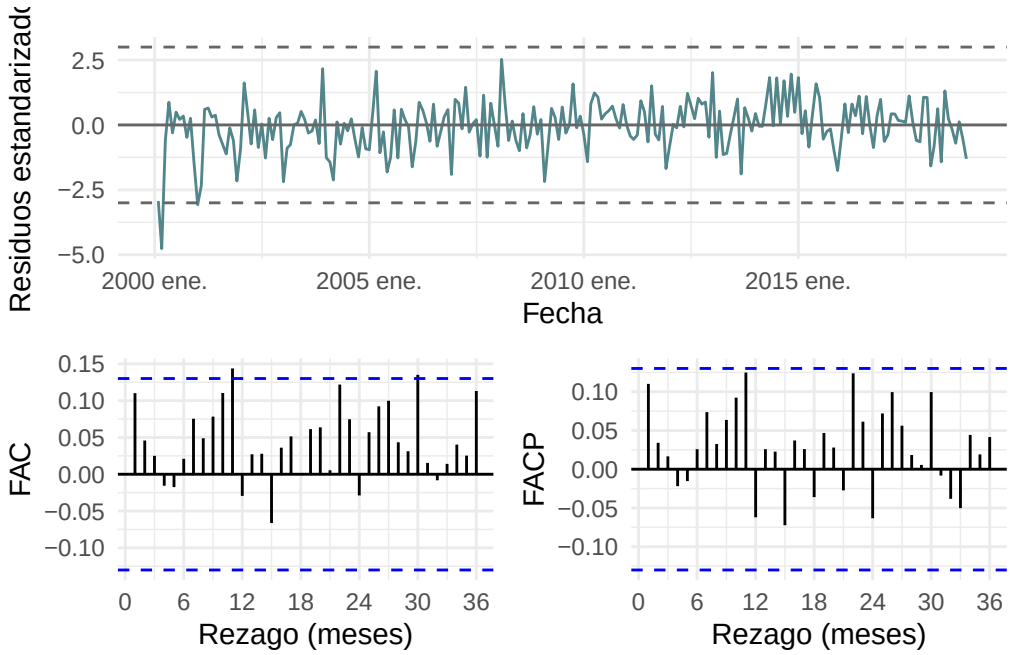


Figura 11: Residuos estandarizados del modelo ARIMA(0,1,2)(0,1,1)[12], con su FAC y FACP

Los residuos estandarizados (Figura Figura 11) oscilan alrededor de cero con variabilidad aproximadamente constante. Se identifica una observación al inicio de la serie por fuera del intervalo $(-3, 3)$. La FAC y la FACP de los residuos se mantienen mayormente dentro de las bandas de significancia, con un único rezago (el 12) apenas por fuera en la FAC, lo cual es compatible con el azar al evaluar 36 rezagos y con el resultado del test de Portmanteau.

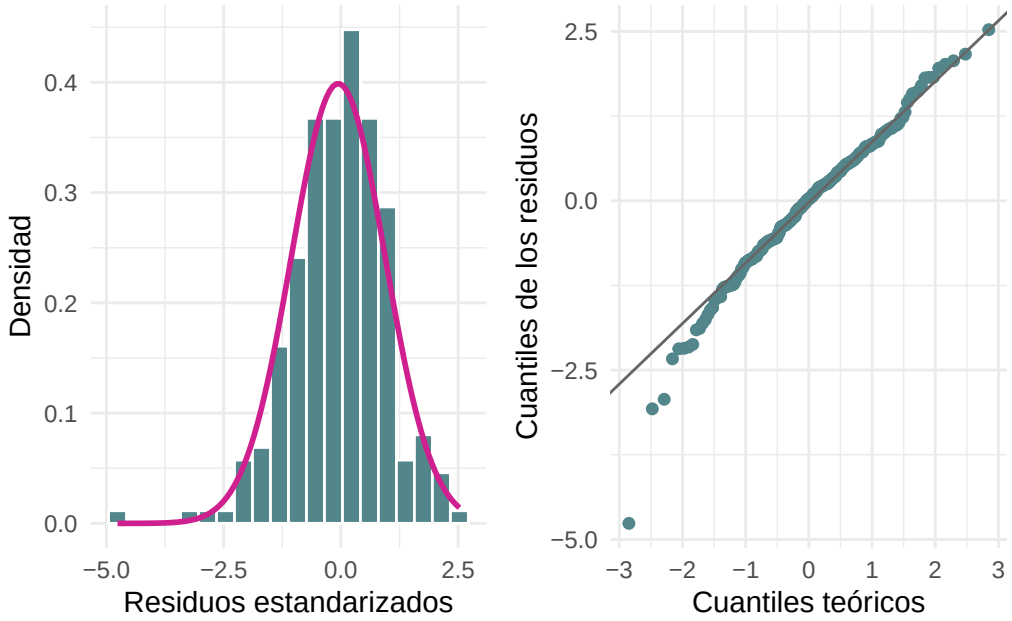


Figura 12: Histograma y QQ-plot de los residuos estandarizados del modelo ARIMA(0,1,2)(0,1,1)[12]

El histograma y el QQ-plot (Figura Figura 12) muestran una distribución aproximadamente normal, con una cola izquierda algo más pesada debida a los valores extremos mencionados. Además, se realizó el test de Shapiro-Wilk, en donde se rechaza la hipótesis de normalidad de los residuos (p-value = 0,0006). Este apartamiento se concentra en la cola izquierda y se debe principalmente a dos observaciones atípicas, correspondientes a marzo de 2000 y enero de 2001, cuyos residuos estandarizados superan en valor absoluto el valor 3. Dado que el test de Portmanteau no detecta autocorrelación remanente, la falta de normalidad no afecta los pronósticos puntuales, pero sí podría afectar la exactitud de los intervalos de pronóstico, que se construyen bajo el supuesto de normalidad.

Se realiza el ajuste para el modelo SARIMA$(0,1,1)(0,1,1)_{12}$ sobre la serie transformada Z_t:

$$(1-B)(1-B^{12})Z_t = (1-\theta_1 B)(1-\Theta_1 B^{12})\, a_t,$$

donde Z_t es la serie transformada mediante Box-Cox con $\hat{\lambda} = -0{,}90$ y a_t es ruido blanco. De esta forma, el modelo estimado queda:

$$(1-B)(1-B^{12})Z_t = (1-0{,}5526B)(1-0{,}7872B^{12})\, a_t.$$

Se presenta una tabla con los valores de los coeficientes estimados, acompañados de un IC para probar su significación.

Tabla 4: Coeficientes estimados del modelo ARIMA(0,1,1)(0,1,1)[12]

Parámetro	Estimación	Error estándar	IC 95 % inferior	IC 95 % superior
ma1	-0.5526	0.0684	-0.6866	-0.4186
sma1	-0.7872	0.0559	-0.8967	-0.6777

Dado que ningún intervalo contiene al cero, se concluye que los dos parámetros son significativos con un nivel de significación del 5 %. Además, el coeficiente estacional ($-0{,}79$) se aleja de -1, por lo que el modelo es invertible.

Se procede con el análisis de los residuos, excluyendo las primeras 13 observaciones, ya que dependen de las condiciones iniciales de la diferenciación. Se inicia con el test de Portmanteau para verificar la hipótesis de que los residuos son ruido blanco:

Tabla 5: Test de Portmanteau de los residuos del modelo ARIMA(0,1,1)(0,1,1)[12]

Rezago	Estadística	gl	p-value
6	10.761	4	0.029
12	22.309	10	0.014
18	24.399	16	0.081
24	31.097	22	0.094

El test rechaza la hipótesis de ruido blanco, con un nivel de significación del 5 %, en los rezagos 6 (p-value = 0,029) y 12 (p-value = 0,014). En los rezagos 18 y 24 no se rechaza, aunque los p-values (0,081 y 0,094) son cercanos al umbral. Esto indica que los residuos conservan autocorrelación que el modelo no logra explicar.

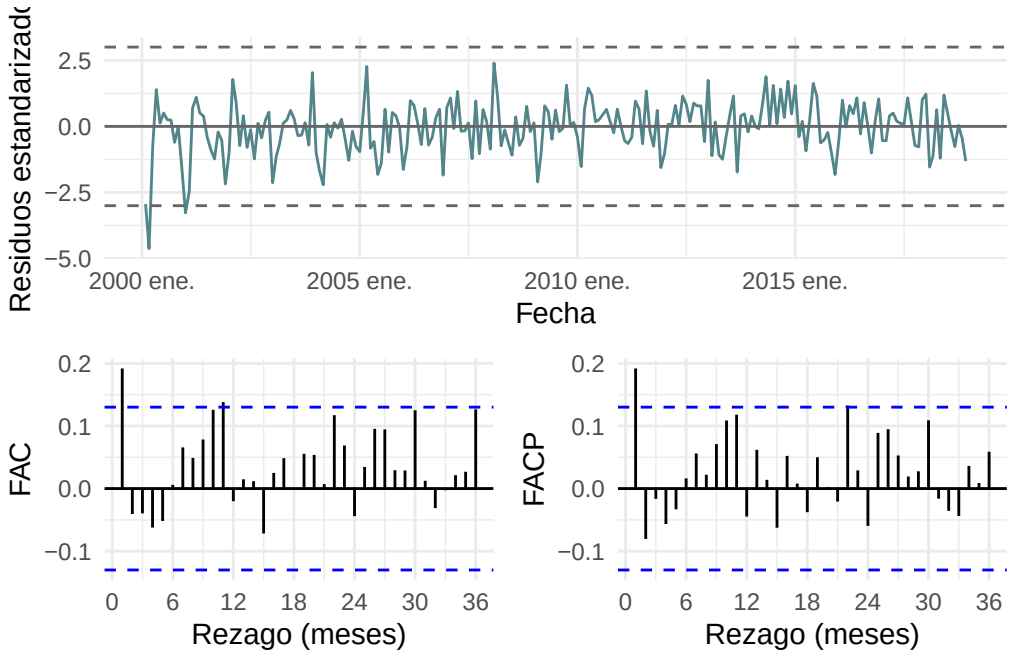


Figura 13: Residuos estandarizados del modelo ARIMA(0,1,1)(0,1,1)[12], con su FAC y FACP

Los residuos estandarizados oscilan alrededor de cero con variabilidad aproximadamente constante, aunque se observan dos valores por fuera del intervalo $(-3, 3)$ al inicio de la serie. En la FAC y la FACP el rezago 1 supera claramente la banda de significancia, y los rezagos 10 y 11 se ubican en el límite. Esto es coherente con el resultado del test de Portmanteau: persiste dependencia de corto plazo no capturada por el modelo.

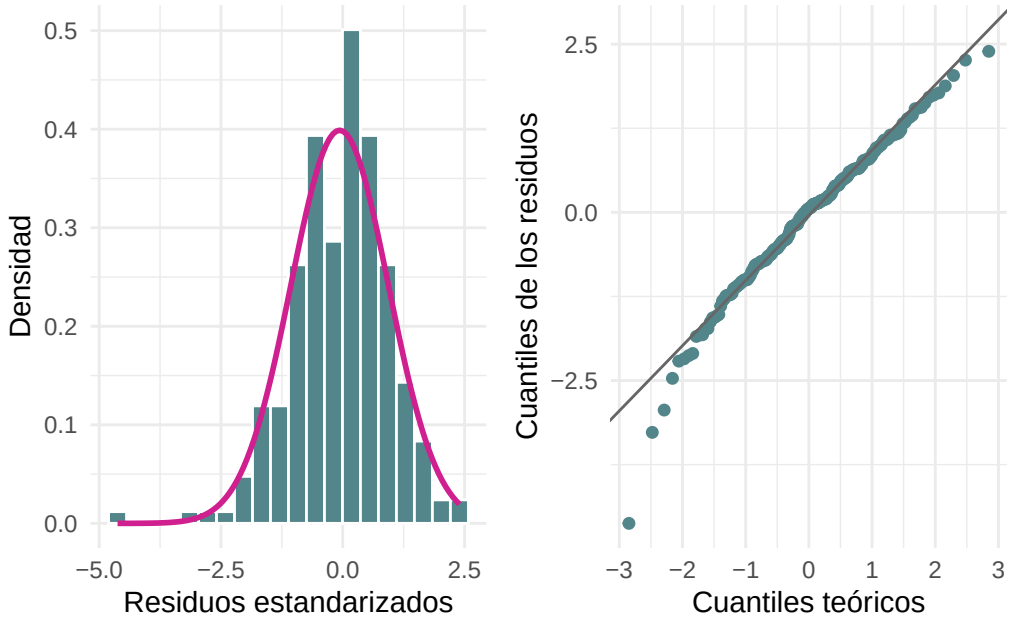


Figura 14: Histograma y QQ-plot de los residuos estandarizados del modelo ARIMA(0,1,1)(0,1,1)[12]

El histograma se aproxima a una distribución normal, con una cola izquierda algo más pesada. En el QQ-plot los puntos siguen la recta, salvo en el extremo inferior, donde se separan los valores atípicos mencionados. Además, se realizó el test de Shapiro-Wilk sobre los residuos para evaluar normalidad, el cuál rechazamla hipótesis (p-value = 0,0010). Este apartamiento se concentra en la cola izquierda y se debe a las observaciones atípicas del inicio de la serie.

En síntesis, aunque los coeficientes son significativos, este modelo no pasa el diagnóstico: los residuos presentan autocorrelación remanente y no son normales.

Se procede a comparar ambos modelos considerados:

Tabla 6: Comparación de los modelos SARIMA considerados

Modelo	AICc	BIC	MAPE (%)
ARIMA(0,1,1)(0,1,1)[12]	-4870.79	-4860.62	3.61
ARIMA(0,1,2)(0,1,1)[12]	-4874.32	-4860.80	3.57

En síntesis, el modelo SARIMA$(0,1,2)(0,1,1)_{12}$ presenta coeficientes significativos y residuos sin autocorrelación remanente, con la salvedad de la falta de normalidad debida a dos observaciones atípicas.

Al comparar ambos modelos (Tabla Tabla 6), el SARIMA$(0,1,2)(0,1,1)_{12}$ presenta un AICc menor (diferencia de aproximadamente 3,5 puntos), mientras que el BIC y el MAPE son

prácticamente equivalentes. Dado que los criterios de información no distinguen claramente entre ambos, el diagnóstico de los residuos resulta determinante: el SARIMA$(0,1,2)(0,1,1)_{12}$ es el único cuyos residuos no muestran autocorrelación remanente, y todos sus coeficientes son significativos. Por lo tanto, se lo selecciona como modelo final para la etapa de pronóstico.

Evaluación predictiva del modelo seleccionado

Para la etapa de pronósticos, se ajusta el modelo SARIMA seleccionado utilizando los datos disponibles hasta diciembre de 2018 y se generan predicciones para las doce observaciones del año 2019, que constituyen la muestra de evaluación. Además, se comparan los valores pronosticados con los datos reales de 2019 a fin de evaluar el desempeño del modelo y analizar su capacidad predictiva.

Mes	Valor real	Pronóstico	IC del 95 %
enero	13.447	NA	(NA; 3434)
febrero	12.125	NA	(NA; 2985)
marzo	13.433	NA	(NA; 2909)
abril	12.443	NA	(NA; 2743)
mayo	12.232	NA	(NA; 2637)
junio	11.556	NA	(NA; 2508)
julio	11.870	NA	(NA; 2444)
agosto	11.816	NA	(NA; 2378)
septiembre	11.752	NA	(NA; 2303)
octubre	12.693	NA	(NA; 2285)
noviembre	12.955	NA	(NA; 2236)
diciembre	13.683	NA	(NA; 2217)